

# Inhaltsverzeichnis

<b>1</b>	<b>Konzept</b>	<b>2</b>
1.1	Normalized Difference Vegetation Index . . . . .	2
1.2	Sentinel-2 . . . . .	3
1.3	Mask R-CNN . . . . .	4
1.3.1	Grundlagen . . . . .	4
1.3.2	Anforderungen . . . . .	5
1.3.3	Mask R-CNN . . . . .	5
	Abbildungsverzeichnis . . . . .	8
	<b>Abbildungsverzeichnis</b>	<b>8</b>
	<b>Literaturverzeichnis</b>	<b>9</b>
	<b>Erklärung</b>	<b>11</b>

# Kapitel 1

## Konzept

### 1.1 Normalized Difference Vegetation Index

Es gibt eine starke Korrelation zwischen dem physiologischen Status einer Pflanze und deren Chlorophyllgehalt. Faktoren wie Krankheit, Dürre oder Umweltverschmutzung haben einen negativen Einfluss auf den Chlorophyllspiegel.[8] Messungen haben ergeben, dass es eine Verbindung zwischen dem Reflexionsgrad im nahen Infrarotbereich und im Rotbereich und dem Chlorophyllgehalt gibt. Das heißt, dass eine gesunde, adulte Pflanze im nahen Infrarotbereich stärker reflektiert als zum Beispiel eine pathologisch veränderte Pflanze. Jedoch bleibt die Reflexion im roten Lichtspektrum in beiden Fällen vergleichsweise schwach. Andere vegetationsfreie Oberflächen wie Acker, Straßen oder Wasser strahlen auch im nahen Infrarotbereich schwach zurück. Dadurch ergibt sich eine zerstörungsfreie Methode, mit einer Multispektralkamera die Vitalität („Grünheit“) einer oder mehrerer Pflanzen zu bestimmen.[6]

Eine multispektralen Aufnahme kann mithilfe der Formel

$$NDVI = \frac{Band_{NIR} - Band_{Red}}{Band_{NIR} + Band_{Red}} \quad (1.1)$$

dazu genutzt werden, den *Normalized Difference Vegetation Index* (NDVI) zu berechnen. Wobei  $Band_{NIR}$  der nahe Infrarotbereich (Near Infrared) und  $Band_{RED}$  der sichtbare rote Bereich des elektromagnetischen Spektrums ist. Der NDVI gibt quantifizierte Werte im Bereich von  $-1$  bis  $1$  zurück. Dabei deuten Werte, die kleiner als  $0$  sind, auf Wasseroberflächen hin.  $0$  bedeutet keine Vegetation. Bei Werten nahe  $0$  handelt es sich um spärliche oder ungesunde Vegetation. Das bedeutet je näher ein Wert an  $1$  ist, desto dichter bewachsen und gesünder ist die beobachtete Vegetationsfläche.[10] Dass bei einem niedrigen, positiven NDVI nicht unterschieden

werden kann, ob eine Fläche kaum bewachsen ist oder ungesunde Vegetation besitzt, kann hier vernachlässigt werden. Das Gebiet, das in dieser Arbeit untersucht wird, ist ein bewachsenes Feld, so kann man geringe Vegetation ausschließen.

## 1.2 Sentinel-2

Die Sentinel-2-Satelliten sind eine von sechs Satellitenarten (Sentinel-1 bis -6) des Copernicus-Programms<sup>1</sup>, die zur Erdbeobachtung in einen 786 km hohen sonnensynchronen Orbit gebracht wurden. Die Instrumente der Sentinel-2-Satelliten können Aufnahmen in Bereichen des roten und nahen Infrarot- bis hin zum Kurzwelleninfrarotspektrums. Die Aufnahmen haben Gesamtgröße von 100 \* 100 km und je nach Band eine von Auflösung von 10m, 20m oder 60m (s. Tabelle 1.1).

Bandnummer	Räumliche Auflösung	Mittlere Wellenlänge (nm)	Bandbreite (nm)
B1	60	443,9	27
B2	10	496,6	98
B3	10	560	45
B4	10	664,5	38
B5	20	703,9	19
B6	20	740,2	18
B7	20	782,5	28
B8	10	835,1	145
B8a	20	864,8	33
B9	60	945	26
B10	60	1373,5	75
B11	20	1613,7	143
B12	20	2202,4	242

Tabelle 1.1: Räumliche und spektrale Auflösungen von Sentinel-2A[4]

Besonders wichtig sind die Bänder B4 (Rot) und B8 (Nahes Infrarot). Mit diesen Bändern kann der NDVI (s. Kapitel 1.1) berechnet werden.[3] Die Sentinel-2-Satelliten bieten mit 10 \* 10 m pro Pixel eine hohe räumliche Auflösung.<sup>2</sup> Diese Eigenschaft ist wichtig, um eine mögliche Infizierung genau eingrenzen zu können.

<sup>1</sup>Das Copernicus-Programm wurde von der Europäischen Union zur Erdbeobachtung ins Leben gerufen. Die gesammelten Daten werden für wissenschaftliche, wirtschaftliche und private Anwendungszwecke zur Verfügung gestellt.[2]

<sup>2</sup>Im Vergleich hat zum Beispiel der Landsat-8-Satellit, dessen Daten ebenfalls frei verfügbar sind, eine relativ geringe Auflösung von 30 \* 30 m.

Dabei ist es auch wichtig, dass die Satelliten regelmäßige Daten liefern können. Durch die gemeinsame Konstellation übertragen die Plattformen alle fünf Tage Daten über einen spezifischen Punkt auf der Erdoberfläche.[5] Damit ist gewährleistet, dass der Feldbesitzer ohne persönliche Inspektion ein bis zweimal in der Woche eine Gesundheitseinschätzung über seine Felder erhält.

## 1.3 Mask R-CNN

In Kapitel 1.1 und 1.2 wurde erklärt wie Daten über die möglichen Erkrankungen geliefert und verarbeitet werden können. Auf den zugrunde liegenden Bilddaten soll nun ein künstliches neuronales Netzwerk (KNN) trainiert werden. In diesem Kapitel wird darauf eingegangen, welche Anforderungen an das KNN gestellt werden, warum das Titel gebende Netz ausgewählt wurde und wie dieses funktioniert.

### 1.3.1 Grundlagen




Abbildung 1.1: Künstliches neuronales Netz[12]

Künstliche neuronale Netze sind nach dem Vorbild von biologischen neuronalen Netzen gebildet worden. So ist ein KNN ebenfalls eine Verbindung von künstlichen Neuronen. Diese Neuronen sind in Schichten angeordnet und jede die Neuronen einer Schicht sind mit den Neuronen nächsten bzw. letzten Schicht verbunden. Ein Neuron besitzt mehrere Eingangsverbindungen (Gewichte) und ein Ausgangsneuron. Ob ein Neuron „feuert“, wird durch eine lineare oder nicht-lineare Aktivierungsfunktion bestimmt. Die Eingangsgewichte sind veränderbare Werte, die je nach Höhe einen starken oder niedrigen Einfluss auf die Aktivierungsfunktion haben.

$$x_j^{l+1} = f(\sum_i w_{ij}^l x_i^l + w_{bj}^l) \quad (1.2)$$

beschreibt das Neuron  $j$  in Schicht  $l + 1$ , wobei

- $w_{ij}^l$  die Gewichte sind, die Neuron  $i$  in Schicht  $l$  mit Neuron  $j$  verbinden.
- $w_{bj}^l$  der Biasterm des  $j$ -ten Neurons in Schicht  $l$  ist.
- $f$  die Aktivierungsfunktion ist.[12]

*Convolutional Neural Networks* (CNN, dt.: faltendes neurales Netzwerk) sind eine Kategorie von KNNs, die besonders in *Computer Vision* Anwendung finden. CNNs extrahieren durch Faltungen sog. Feature Maps. Die Dimensionen der Feature Maps werden in einem Poolingschritt<sup>3</sup> reduziert.

### 1.3.2 Anforderungen

Das KNN muss in der Lage sein, wahrscheinliche Krankheiten in der zu untersuchenden Agrarfläche möglichst genau eingrenzen und klassifizieren zu können. Das ist besonders wichtig, wenn ein Feld von multiplen Krankheiten betroffen ist.

Es ist damit zu rechnen, dass Daten unter bewölkten Bedingungen aufgenommen werden. Nach starken Niederschlägen können Acker teils oder gänzlich überflutet sein.[9] Das sorgt selbst unter wolkenfreien Bedingungen für einen niedrigen NDVI, obwohl die Nutzpflanzen gesund sind. Das neuronale Netz muss mit solchen „Ausreißern“ umgehen können.

Daraus ergeben sich folgende Kriterien für das neuronale Netzwerk:

- Erkennung auf Pixelebene
- Robustheit
- Hohe Genauigkeit

### 1.3.3 Mask R-CNN

Im Rahmen dieser Arbeit wird das *Mask Region-based Convolutional Neural Network* untersucht. Mask R-CNN ist eine von Facebook AI Research entwickelte Erweiterung des *Faster R-CNN* und kann verschiedene Instanzen einer Klasse in einem Bild von einander trennen. Dazu muss zuerst die Begriffe der Instanzsegmentierung definiert werden.

<sup>3</sup>Es gibt verschiedene Arten von Pooling (Max, Average, Sum, ...). Dabei wird die Feature Map in sich nicht-überschneidene  $m * m$  px große Felder eingeteilt. Im Falle von Max-Pooling wird aus der höchste Wert aus dem Feld genommen.

Hier sollte ggf. noch die Erklärung von Training und Validierung hin. Oder doch eigenes Kapitel in overfitting?

Einfache Klassifizierung (engl.: classification) ordnet Bilder als Ganzes einer Klasse

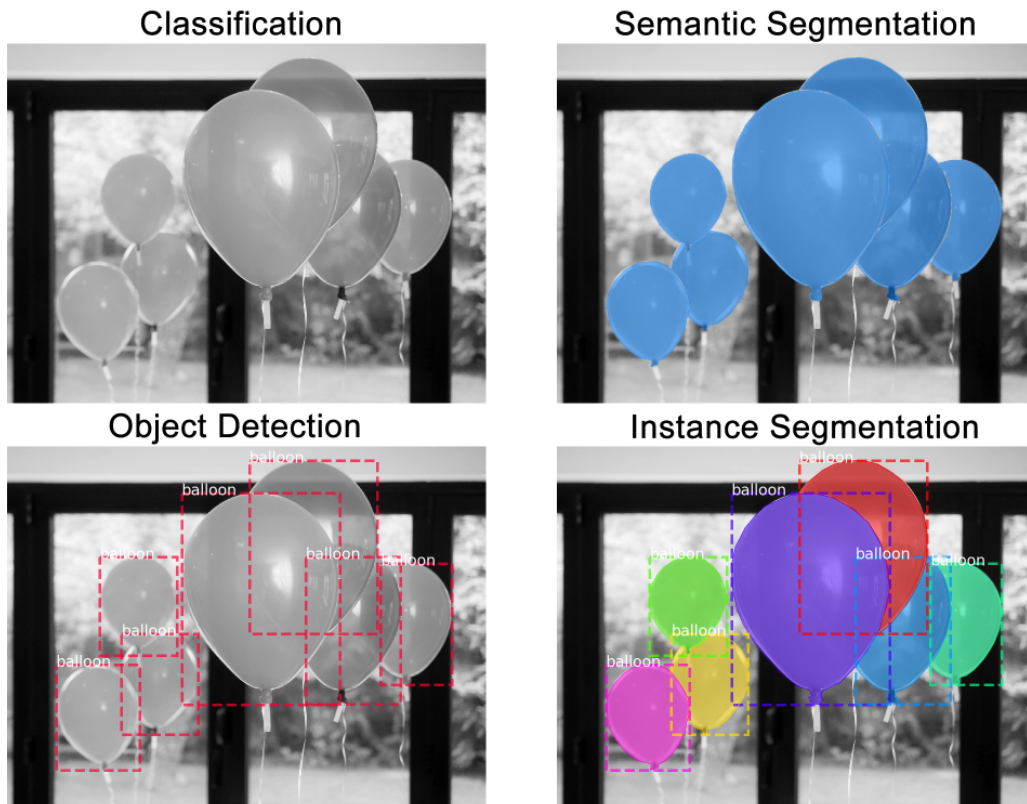


Abbildung 1.2: Unterschied Klassifizierung / semantische Segmentierung / Objekterkennung / Instanzsegmentierung[1]

zu. *Semantische Segmentierung* (engl.: semantic segmentation) beschreibt die Klassifizierung auf Pixelebene. Es wird erkannt zu welcher Klasse eine Menge von Pixeln gehören, aber es wird nicht zwischen einzelnen Objekten unterschieden. *Objekterkennung* (engl.: object detection) entdeckt und lokalisiert unterschiedliche Objekte, indem es eine Bounding Box um jedes erkannte Objekt zieht. Jedoch fehlt hier die pixelgenaue Abgrenzung einzelner Objektinstanzen. Instanzsegmentierung (engl.: instance segmentation) kombiniert *Objekterkennung* und *semantische Segmentierung* und ist so in der Lage zwischen einzelnen Objekten zu unterscheiden und ihnen entsprechende Pixel zuzuordnen (s. Abb. 1.2) und ist eine der größten Herausforderungen in der Bildverarbeitung.[7]

Mask R-CNN ist wie Faster R-CNN in zwei Segmente eingeteilt. In dem ersten Segment, dem *Region Proposal Network* (RPN), werden mehrere Rahmen (Bounding Boxes) innerhalb eines Bildes vorgeschlagen, die interessante Objekte beinhalten

können.[11] Die vorgeschlagene Rahmen oder auch Regionen, die einzeln von CNNs bewertet werden, ist der Kernansatz von R-CNN. Das RPN wurde identisch von Faster R-CNN für Mask R-CNN übernommen.[7]

Im zweiten Segment werden die Rahmen klassifiziert. Die Rahmen haben verschiedene Größen und können Probleme bei der Klassifizierung verursachen. Daher werden die Rahmen auf eine kleine Feature Map gleicher Größe (z.B.  $7 * 7$  px) reduziert. Die Autoren von [7] schlagen eine Methode namens *RoI-Align* vor, bei der Proben aus der Feature Map entnommen werden und eine bilineare Interpolation angewendet wird. In dem bei Faster R-CNN angewandten Verfahren *RoI-Pooling* entstehen durch Quantisierung Informationsverluste und räumliche Abweichungen zwischen Bounding Box und Feature Map, was negative Auswirkungen auf die Maskengenerierung haben kann.

Gleichzeitig werden in einem parallelen Zweig für jede Bounding Box  $k * m * n$  große binären Maske erzeugt, wobei  $k$  die Anzahl der vorhergesagten Klassen ist. Typischerweise für semantische Segmentierung werden die Klassen auf eine Maske abgebildet, was dafür sorgt, dass die Klassen konkurrieren müssen. Durch die separaten Masken erreicht Mask R-CNN gute Ergebnisse bei der Instanzsegmentierung.[7]

# Abbildungsverzeichnis

1.1	Künstliches neuronales Netz . . . . .	4
1.2	Instansegmentierung . . . . .	6



# Literaturverzeichnis

- [1] W. Abdulla. Splash of color: Instance segmentation with mask r-cnn and tensorflow. <https://engineering.matterport.com/splash-of-color-instance-segmentation-with-mask-r-cnn-and-tensorflow-7c761e238> 2018. [Zuletzt besucht: 22.12.2018].
- [2] Copernicus. Copernicus in brief. <https://www.copernicus.eu/en/about-copernicus/copernicus-brief>. [Zuletzt besucht: 15.12.2018].
- [3] ESA. Level-2a algorithm overview. <https://sentinel.esa.int/web/sentinel/technical-guides/sentinel-2-msi/level-2a/algorithm>, 2018. [Zuletzt besucht: 20.12.2018].
- [4] ESA. Radiometric resolutions. <https://earth.esa.int/web/sentinel/user-guides/sentinel-2-msi/resolutions/radiometric>, 2018. [Zuletzt besucht: 20.12.2018].
- [5] ESA. Resolutions. <https://earth.esa.int/web/sentinel/user-guides/sentinel-2-msi/resolutions>, 2018. [Zuletzt besucht: 20.12.2018].
- [6] A. A. Gitelson, Y. Gritz, and M. N. Merzlyak. Relationships between leaf chlorophyll content and spectral reflectance and algorithms for non-destructive chlorophyll assessment in higher plant leaves. *Journal of Plant Physiology*, 160(3):271 – 282, 2003.
- [7] K. He, G. Gkioxari, P. Dollár, and R. B. Girshick. Mask R-CNN. *CoRR*, abs/1703.06870, 2017.
- [8] G. A. F. Hendry, J. D. HOUGHTON, and S. B. BROWN. The degradation of chlorophyll — a biological enigma. *New Phytologist*, 107(2):255–302, 1987.
- [9] C. Mattupalli, C. A. Moffet, K. N. Shah, and C. A. Young. Supervised classification of rgb aerial imagery to evaluate the impact of a root rot disease. *Remote Sensing*, 10(6), 2018.

- [10] NASA. Measuring vegetation (ndvi & evi). [https://earthobservatory.nasa.gov/features/MeasuringVegetation/measuring\\_vegetation\\_2.php](https://earthobservatory.nasa.gov/features/MeasuringVegetation/measuring_vegetation_2.php), 2000. [Zuletzt besucht: 13.12.2018].
- [11] S. Ren, K. He, R. B. Girshick, and J. Sun. Faster R-CNN: towards real-time object detection with region proposal networks. *CoRR*, abs/1506.01497, 2015.
- [12] J. Verrelst, J. Muñoz, L. Alonso, J. Delegido, J. P. Rivera, G. Camps-Valls, and J. Moreno. Machine learning regression algorithms for biophysical parameter retrieval: Opportunities for sentinel-2 and -3. *Remote Sensing of Environment*, 118:127 – 139, 2012.

# Erklärung

Ich versichere, dass ich die vorliegende Arbeit selbstständig und nur unter Verwendung der angegebenen Quellen und Hilfsmittel angefertigt habe, insbesondere sind wörtliche oder sinngemäße Zitate als solche gekennzeichnet. Mir ist bekannt, dass Zuwiderhandlung auch nachträglich zur Aberkennung des Abschlusses führen kann.

Ich versichere, dass das elektronische Exemplar mit den gedruckten Exemplaren übereinstimmt.

Ort:

Datum:

Unterschrift: