

Zusammenfassung

Hier kommt ein Abstrakt hin.

Inhaltsverzeichnis

1 Methoden	2
1.1 Trainingsdaten	2
1.2 Normalized Difference Vegetation Index	3
1.3 Sentinel-2	3
1.4 Das trainierbare Modell	5
1.4.1 Anforderungen	5
1.4.2 Grundlagen	5
1.4.3 Mask R-CNN	7
2 Overfitting	12
2.1 Begriffserklärung	12
2.2 Data Augmentation	13
2.3 L2 Regularization	14
2.4 Zusätzliche Methoden	15
3 Konzept und Implementierung	16
3.1 Konzept	16
3.2 Annotation	17
3.3 Suche nach Sentinelprodukte	19
3.4 Aufbereitung der Sentineldaten	20
3.5 Trainings- und Validierungsdatensatz	21
3.6 Training	23
Abbildungsverzeichnis	28
Tabellenverzeichnis	29
Literaturverzeichnis	30
Erklärung	33

Kapitel 1

Methoden

1.1 Trainingsdaten



Abbildung 1.1: RGB-Sentinel-2-Aufnahme des zu untersuchenden Ackers. Die infizierten Flächen sind weiß umrandet.

Der infizierte Acker, der die Basis des Datensatzes bildet, befindet sich etwa 15 km nordwestlich von Bologna in Norditalien ($44^{\circ}34'28.92''$ Nord, $11^{\circ}10'21.36''$ Ost). Das Feld hat eine Fläche von $7640,57 \text{ m}^2$ und ist mit Sorghum bepflanzt. Mitarbeiter des CREA (Council for Agricultural Research and Economics) haben vor Ort am 12.07.2018 Befälle von Anthracnose und der bakteriellen Streifenkrankheit (med.: *Xanthomonas translucens*) diagnostiziert. Etwa die Hälfte der Pflanzen des Feldes sind betroffen. Dabei sind im östlichen Teil des Feldes (Abb. 1.1, innere Markierung) auf einer Fläche von $1043,22 \text{ m}^2$ von etwa 60 bis 70% der Pflanzen befallen.

1.2 Normalized Difference Vegetation Index

Es gibt eine starke Korrelation zwischen dem physiologischen Status einer Pflanze und deren Chlorophyllgehalt. Faktoren wie Krankheit, Dürre oder Umweltverschmutzung haben einen negativen Einfluss auf den Chlorophyllspiegel.[14] Messungen haben ergeben, dass es eine Verbindung zwischen dem Reflexionsgrad im nahen Infrarotbereich und im Rotbereich und dem Chlorophyllgehalt gibt. Das heißt, dass eine gesunde, adulte Pflanze im nahen Infrarotbereich stärker reflektiert als zum Beispiel eine pathologisch veränderte Pflanze. Jedoch bleibt die Reflexion im roten Lichtspektrum in beiden Fällen vergleichsweise schwach. Andere vegetationsfreie Oberflächen wie Acker, Straßen oder Wasser strahlen auch im nahen Infrarotbereich schwach zurück. Dadurch ergibt sich eine zerstörungsfreie Methode, mit einer Multispektralkamera die Vitalität („Grünheit“) einer oder mehrerer Pflanzen zu bestimmen.[12]

Eine multispektralen Aufnahme kann mithilfe der Formel

$$NDVI = \frac{Band_{NIR} - Band_{Red}}{Band_{NIR} + Band_{Red}} \quad (1.1)$$

dazu genutzt werden, den *Normalized Difference Vegetation Index* (NDVI) zu berechnen. Wobei $Band_{NIR}$ der nahe Infrarotbereich (Near Infrared) und $Band_{RED}$ der sichtbare rote Bereich des elektromagnetischen Spektrums ist. Der NDVI gibt quantifizierte Werte im Bereich von -1 bis 1 zurück. Dabei deuten Werte, die kleiner als 0 sind, auf Wasserobflächen hin. 0 bedeutet keine Vegetation. Bei Werte nahe 0 handelt es sich um spärliche oder ungesunde Vegetation. Das bedeutet je näher ein Wert an 1 ist, desto dichter bewachsen und gesünder ist die beobachtete Vegetationsfläche.[17] Dass bei einem niedrigen, positiven NDVI nicht unterschieden werden kann, ob eine Fläche kaum bewachsen ist oder ungesunde Vegetation besitzt, kann hier vernachlässigt werden. Das Gebiet, das in dieser Arbeit untersucht wird, ist ein bewachsenes Feld, so kann man geringe Vegetation ausschließen.

1.3 Sentinel-2

Die Sentinel-2-Satelliten sind eine von sechs Satellitenarten (Sentinel-1 bis -6) des Copernicus-Programms¹, die zur Erdbeobachtung in einen 786 km ho-

¹Das Copernicus-Programm wurde von der Europäischen Union zur Erdbeobachtung ins Leben gerufen. Die gesammelten Daten werden für wissenschaftliche, wirtschaftliche und

hen sonnensynchronen Orbit gebracht wurden. Die Instrumente der Sentinel-2-Satelliten können Aufnahmen in Bereichen des roten und nahen Infrarot- bis hin zum Kurzwelleninfrarotspektrums. Die Aufnahmen haben Gesamtgröße von $100 * 100$ km und je nach Band eine von Auflösung von 10m, 20m oder 60m (s. Tabelle 1.1).

Bandnummer	Räumliche Auflösung	Mittlere Wellenlänge (nm)	Bandbreite (nm)
B1	60	443,9	27
B2	10	496,6	98
B3	10	560	45
B4	10	664,5	38
B5	20	703,9	19
B6	20	740,2	18
B7	20	782,5	28
B8	10	835,1	145
B8a	20	864,8	33
B9	60	945	26
B10	60	1373,5	75
B11	20	1613,7	143
B12	20	2202,4	242

Tabelle 1.1: Räumliche und spektrale Auflösungen von Sentinel-2A[10]

Besonders wichtig sind die Bänder B4 (Rot) und B8 (Nahes Infrarot). Mit diesen Bändern kann der NDVI (s. Kapitel 1.2) berechnet werden.[9] Die Sentinel-2-Satelliten bieten mit $10 * 10$ m pro Pixel eine hohe räumliche Auflösung.² Diese Eigenschaft ist wichtig, um eine mögliche Infizierung genau eingrenzen zu können.

Dabei ist es auch wichtig, dass die Satelliten regelmäßige Daten liefern können. Durch die gemeinsame Konstellation übertragen die Plattformen alle fünf Tage Daten über einen spezifischen Punkt auf der Erdoberfläche.[11] Damit ist gewährleistet, dass der Feldbesitzer ohne persönliche Inspektion ein bis zweimal in der Woche eine Gesundheitseinschätzung über seine Felder erhält.

private Anwendungszwecke zur Verfügung gestellt.[7]

²Im Vergleich hat zum Beispiel der Landsat-8-Satellit, dessen Daten ebenfalls frei verfügbar sind, eine relativ geringe Auflösung von $30 * 30$ m.[21]

1.4 Das trainierbare Modell

In Kapitel 1.2 und 1.3 wurde erklärt wie Daten über die möglichen Erkrankungen geliefert und verarbeitet werden können. Auf den zugrunde liegenden Bilddaten soll nun ein künstliches neuronales Netzwerk (KNN) trainiert werden. In diesem Kapitel wird darauf eingegangen, welche Anforderungen an das KNN gestellt werden, warum das Titel gebende Netz ausgewählt wurde und wie dieses funktioniert.

1.4.1 Anforderungen

Das KNN muss in der Lage sein, wahrscheinliche Krankheiten in der zu untersuchenden Agrarfläche möglichst genau eingrenzen und klassifizieren zu können. Das ist besonders wichtig, wenn ein Feld von multiplen Krankheiten betroffen ist.

Es ist damit zu rechnen, dass Daten unter bewölkten Bedingungen aufgenommen werden. Nach starken Niederschlägen können Acker teils oder gänzlich überflutet sein.[16] Das sorgt selbst unter wolkenfreien Bedingungen für einen niedrigen NDVI, obwohl die Nutzpflanzen gesund sind. Das neuronale Netz muss mit solchen „Ausreißern“ umgehen können.

Daraus ergeben sich folgende Kriterien für das neuronale Netzwerk:

- Erkennung auf Pixelebene
- Robustheit
- Hohe Genauigkeit

1.4.2 Grundlagen

Vollständig vernetztes neuronales Netz

Künstliche neuronale Netze sind mathematische Modelle, die nach dem Vorbild von biologischen neuronalen Netzen gebildet worden sind. So ist ein KNN ebenfalls eine Verbindung von künstlichen Neuronen. Diese Neuronen sind in Schichten angeordnet und jede die Neuronen einer Schicht sind mit den Neuronen nächsten bzw. letzten Schicht verbunden. Zwischen der ersten und der

letzten sog. Ausgangsschicht existieren n versteckte Schichten (engl.: hidden layers).




Abbildung 1.2: Künstliches neuronales Netz[22]

Ein Neuron besitzt mehrere Eingangsverbindungen (Gewichte) und ein Ausgangsneuron. Ob ein Neuron „feuert“, wird durch eine lineare oder nicht-lineare Aktivierungsfunktion bestimmt. Die Eingangsgewichte sind veränderbare Werte, die je nach Höhe einen starken oder niedrigen Einfluss auf die Aktivierungsfunktion haben.

$$x_j^{l+1} = f(\sum_i w_{ij}^l x_i^l + w_{bj}^l) \quad (1.2)$$

beschreibt das Neuron j in Schicht $l + 1$, wobei

- w_{ij}^l die Gewichte sind, die Neuron i in Schicht l mit Neuron j verbinden.
- w_{bj}^l der Biasterm des j -ten Neurons in Schicht l ist.
- f die Aktivierungsfunktion ist.[22]

Convolutional Neural Networks

Convolutional Neural Networks (CNN, dt.: faltendes neuronales Netzwerk) sind Kategorien von neuronalen Netzen, die besonders in der *Computer Vision* Anwendung finden. In der ersten Schicht werden mehrere Merkmale (engl.: features) durch Filter extrahiert und in separate sog. *Feature Maps* abgelegt, um größere Abstraktionsebenen zu erreichen. Diese Filter sind mathematisch mit Faltungen (engl.: convolutions) zu vergleichen und geben dem Netz den Namen.

Die Dimensionen der Feature Maps werden in einem Poolingschritt³ (oder

³Es gibt verschiedene Arten von Pooling (Max, Average, Sum, ...). Dabei wird die $m * m$ px große Feature Map in sich angrenzende $n * n$ px große Felder eingeteilt ($n < m$). Im Falle von Max-Pooling wird der höchste Wert aus dem Feld übernommen.




Abbildung 1.3: Architektur eines Convolutional Neural Network[8]

auch *subsampling*) reduziert. Dadurch bleiben nur relevante Informationen erhalten und das CNN wird bis zu einem gewissen Grad robust gegenüber Translationen und Rotationen. In der Regel werden die Faltungen und das Pooling zwei Mal durchgeführt, wie es in Abb. 1.3 abgebildet ist.

Nach der Merkmalsextraktion werden die Feature Maps zur Klassifikation in eine eindimensionale Schichten geglättet. Die folgenden Schichten bis zur Ausgangsschicht sind vollständig vernetzt.

1.4.3 Mask R-CNN

Im Rahmen dieser Arbeit wird das *Mask Region-based Convolutional Neural Network* untersucht. Mask R-CNN ist eine von Facebook AI Research (FAIR) entwickelte Erweiterung des *Faster R-CNN* und kann verschiedene Instanzen einer Klasse in einem Bild voneinander trennen. Dazu muss zuerst die Begriffe der Instanzsegmentierung definiert werden.

Einfache Klassifizierung (engl.: *classification*) ordnet Bilder als Ganzes einer Klasse zu. *Semantische Segmentierung* (engl.: *semantic segmentation*) beschreibt die Klassifizierung auf Pixelebene. Es wird erkannt zu welcher Klasse eine Menge von Pixeln gehören, aber es wird nicht zwischen einzelnen Objekten unterschieden. *Objekterkennung* (engl.: *object detection*) entdeckt und lokalisiert unterschiedliche Objekte, indem es eine Bounding Box um jedes erkannte Objekt zieht. Jedoch fehlt hier die pixelgenaue Abgrenzung einzelner




Abbildung 1.4: Unterschied Klassifizierung / semantische Segmentierung / Objekterkennung / Instanzsegmentierung[2]

Objektinstanzen. Instanzsegmentierung (engl.: instance segmentation) kombiniert *Objekterkennung* und *semantische Segmentierung* und ist so in der Lage zwischen einzelnen Objekten zu unterscheiden und ihnen entsprechende Pixel zuzuordnen (s. Abb. 1.4) und ist eine der größten Herausforderungen in der Bildverarbeitung.[13]




Abbildung 1.5: Mask R-CNN-Architektur[15]

Mask R-CNN ist wie Faster R-CNN in zwei Segmente eingeteilt. In dem ersten Segment, dem *Region Proposal Network* (RPN, dt.: Region vorschlagendes

Netzwerk), werden mehrere Rahmen (Bounding Boxes) innerhalb eines Bildes vorgeschlagen, die interessante Objekte beinhalten könnten.[19] Die vorgeschlagene Regionen, die einzeln von CNNs bewertet werden, ist der Kernansatz von R-CNN. Das RPN wurde identisch von Faster R-CNN für Mask R-CNN übernommen.[13]

Im zweiten Segment werden aus den Regionen *Bounding Boxes* (dt.: Rahmen) und Masken generiert und klassifiziert. Die Rahmen haben verschiedene Größen und können Probleme bei der Klassifizierung verursachen. Daher werden die Rahmen auf eine kleine Feature Map gleicher Größe (z.B. $7 * 7$ px) reduziert. Die Autoren von [13] schlagen eine Methode namens *RoI-Align* vor, bei der Proben aus der Feature Map entnommen werden und eine bilineare Interpolation angewendet wird. In dem bei Faster R-CNN angewandten Verfahren *RoI-Pooling* entstehen durch Quantisierung Informationsverluste und räumliche Abweichungen zwischen Bounding Box und Feature Map, was negative Auswirkungen auf die Maskengenerierung haben kann.[13]

Die oberen vollständig vernetzten Schichten (*FC Layers* in Abb. 1.5) klas-

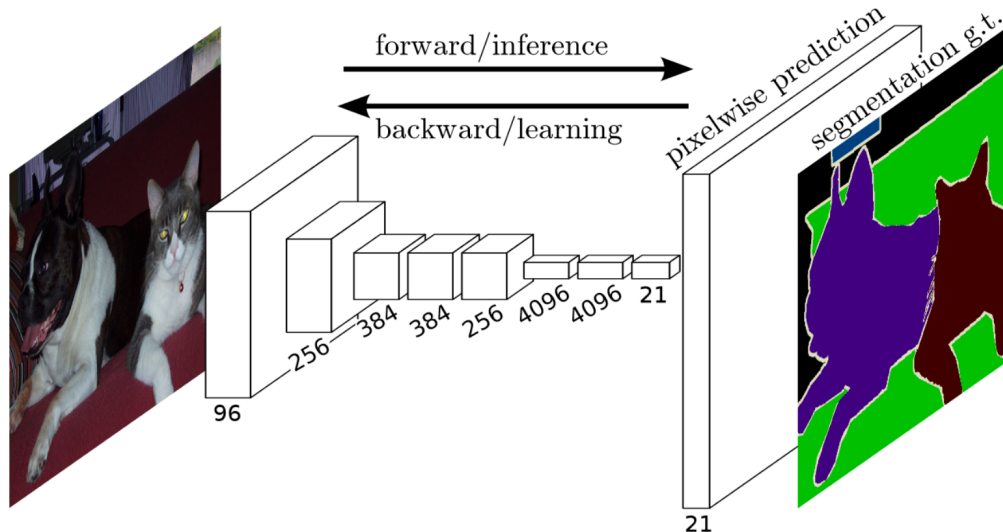


Abbildung 1.6: FCN-Architektur[15]

sifizieren die Regionen und die Bounding Boxes berechnet. Dieser Zweig ist für die Objekterkennung wichtig und noch mit Faster R-CNN gemeinsam.

Gleichzeitig werden in einem parallelen Zweig je Bounding Box $k * m * n$ große Masken zur semantischen Segmentierung erzeugt, wobei k die Anzahl der

Klassen ist. Anders als in dem ersten Zweig des zweiten Segmentes werden die Masken durch *fully convolutional networks* (FCN, dt.: vollständig faltende Netzwerke) prognostiziert. Diese bestehen nur aus faltenden Schichten, wie sie in Kapitel 1.4.2 beschrieben sind. Eine Maske ist eine räumliche Kodierung eines Objektes und daher ist es wichtig räumliche Informationen beizubehalten. Diese können durch die Pixel-zu-Pixel-Übereinstimmung extrahiert werden, welche sonst durch vollständig vernetzter Schichten verloren gehen. Diese geben einen Vektor ohne räumliche Dimensionen aus.[13]

FCN und wie wird Maske erzeugt?

In [13] wird Mask R-CNN mit den *COCO challenge*-Gewinnern⁴ der Jahre




Abbildung 1.7: Bei FCIS entstehen Artefakte, wenn Objekte sich in einem Bild überlappen.[13]

	backbone	AP	AP ₅₀	AP ₇₅	AP _S	AP _M	AP _L
MNC [10]	ResNet-101-C4	24.6	44.3	24.8	4.7	25.9	43.6
FCIS [26] +OHEM	ResNet-101-C5-dilated	29.2	49.5	-	7.1	31.3	50.0
FCIS+++ [26] +OHEM	ResNet-101-C5-dilated	33.6	54.5	-	-	-	-
Mask R-CNN	ResNet-101-C4	33.1	54.9	34.8	12.1	35.6	51.1
Mask R-CNN	ResNet-101-FPN	35.7	58.0	37.8	15.5	38.1	52.4
Mask R-CNN	ResNeXt-101-FPN	37.1	60.0	39.4	16.9	39.9	53.5

Tabelle 1.2: Instance segmentation *mask* AP auf COCO *test-dev*. MNC und FCIS sind Sieger der COCO 2015 und 2016 Challenge. Mask R-CNN erzielt deutlich bessere Ergebnisse als die komplexere FCIS+++.[13]

⁴COCO (Common Objects in Context, dt.: Gewöhnliche Objekte im Kontext) enthält einen Datensatz von über 200000 Bildern in über 80 Kategorien. Der Datensatz ist eine oft genutzte Basis, um Objekterkennungstechniken zu evaluieren und zu bewerten.[6]

2015 und 2016 verglichen. Der Vergleich zeigt, dass Mask R-CNN in der Challenge bessere Werte erzielt als die Konkurrenten (s. Tab. Desweiteren fällt *fully convolutional instance segmentation* (FCIS, dt.: vollständig faltende Instanzsegmentierung) auf, wenn es mit überlappenden Objekten konfrontiert wird. Dort erzeugt es Artefakte, welche durch Mask R-CNN nicht entstehen (s. Abb. 1.7). Durch diese Gegenüberstellungen wird gezeigt, dass Mask R-CNN alle aufgeführten Anforderungen erzielt. Es erkennt Klasseninstanzen auf Pixelebene und weist eine hohe Robustheit auf. Auch die Genauigkeit hebt sich beim direkten Vergleich ab. Aus diesen Gründen wurde Mask R-CNN im Rahmen dieser Arbeit ausgewählt.

Kapitel 2

Overfitting

2.1 Begriffserklärung

Genaue Daten über Krankheitsbefälle im Agrarsektor sind rar, da diese in der Regel nicht öffentlich zugänglich sind.¹ Daher musste mit *Overfitting* gerechnet werden. Das künstliche neurale Netzwerk soll daraufhin trainiert werden, dass es möglichst alle Befälle, die untersucht werden, erkennt. Dafür wird es im ersten Schritt mit einem Trainingsdatensatz trainiert. Im folgenden Schritt mit einem kleineren Validierungsdatensatz überprüft, wie gut das Netz trainiert wird. Overfitting tritt auf, wenn das Netz auf die Daten aus dem Trainingsdatensatz mit sehr hoher Erfolgsquote erkennt, jedoch vergleichsweise schlechte Ergebnisse bei der Validierung bzw. bei unbekannten Daten erzielt. Das geschieht, weil sich das Netz auf nicht relevante Datenpunkte konzentriert, die im nur Trainingsdatensatz auftreten, aber nicht die allgemeine Charakteristika der Objekte widerspiegeln.

In Abb. 2.1 ist ein Beispiel wie Overfitting sich auswirken kann. Die linken zwei Bilder sind ein exemplarischer Auszug aus dem Trainingsdatensatz. Einmal eine visuelle Repräsentation der NDVI-Werte der infizierten Agrarfläche und die Binärmaske, welche die infizierte Fläche markiert. Das selbe Bild wurde nach einem erfolgreichen Trainingsdurchlauf der Mask R-CNN-Implementierung übergeben und es hat den erkrankten Bereich nahezu perfekt erkannt. Das vierte Bild zeigt zentriert das selbe Feld. Jedoch ist der Ausschnitt größer, rotiert und die Aufnahme stammt von einem anderen Datum. Der Prognose zur Folge ist die Infizierung auf die benachbarten Felder über-

Erwähnen,
dass
Mask
RCNN
Bild
und
Mas-
ken
für
Trai-
ning
be-
nö-
tigt.

¹Datenschutz kann ein Grund dafür sein.




Abbildung 2.1: V.l.n.r. Bild von infizierter Agrarfläche aus Trainingsdatensatz / Binärmaske der infizierten Region, wird gemeinsam mit dem linken Bild zum Training in das KNN gespeist / Selbiges Bild, Ergebnis nach Trainingsdurchlauf, prognostizierte Ergebnisfläche in rot / Bild der selben Fläche, was nicht aus dem Trainingsdatensatz stammt, prognostizierte Ergebnisfläche in rot

gesprungen, was nicht der Realität entspricht. Overfitting ist ein bekanntes Problem im Bereich des maschinellen Lernens und es existieren multiple Methoden, um dem entgegenzuwirken.

2.2 Data Augmentation

Generell ist ein sehr großer Datensatz (≥ 10000 Elemente) für das Training förderlich. Jedoch ist das nicht immer möglich. In diesem Fall kann der Datensatz künstlich durch *Data Augmentation* vergrößert werden. Zu Data Augmentation zählen geringe Veränderungen der Daten - hier Bildmanipulationen. Solche Operationen können unter anderem

- Rotationen,
- Spiegelungen,
- Translationen,
- zufällige Ausschnitte,
- Gauß'sches Rauschen,
- Helligkeitsveränderungen,
- oder Kombinationen davon

beinhalten. Wobei nicht jede Augmentation-Technik für jeden Anwendungsfall sinnvoll ist. Wenn zum Beispiel ein KNN auf Autoerkennung trainiert werden soll, ist es nicht nützlich oder sogar hinterlich die Bilddaten so zu rotieren, dass es von oben nach unten oder umgekehrt zeigt. Desweiteren ist

sinnvoll Data Augmentation einzusetzen, obwohl genügend Daten vorhanden sind. So besteht der Datensatz aus zwei Klassen von Autos, Marke A und Marke B. Die Front der Fahrzeuge der Marke A sind nach rechts ausgerichtet, während die Autos der Marke B nach links ausgerichtet sind. Das neuronale Netz wird diesen markanten Unterschied den Marken zuordnen und wird ein links ausgerichtetes Fahrzeug der Marke A als ein Fahrzeug der Marke B klassifizieren.[4]

Für den Anwendungsfall dieser Arbeit sind Rotationen, Spiegelungen, zufällige Ausschnitte und Translationen valide Optionen zur Vergrößerungen des Datensatzes. Wie in dem vorherigen Beispiel wird das Modell auch Merkmale wie Form, Position im Bild oder Ausrichtung der RoI untersuchen, welche in der Realität keine feste Muster haben und nicht vorhersagbar sind. Damit wird nicht nur der Datensatz vergrößert, sondern auch das Modell generalisiert.

Künstliches Rauschen und Helligkeitsveränderungen sind mit hoher Wahrscheinlichkeit nicht geeignet. Die Bilddaten bestehen aus quantifizierten Werten und die Operationen könnten diese Werte verfälschen und damit das Endergebnisse negativ beeinflussen.

2.3 L2 Regularization

Ein kleiner Datensatz führt zu einem komplexen Modell und komplexere Modelle neigen zu Overfitting. *L2 Regularization* (oder auch *Ridge Regression*) vereinfacht das Modell, indem es hohe Gewichte bestraft und niedrige Gewichte bevorzugt.² Hohe Gewichte können mit Anomalien korrelieren, die nur im Trainingsdatensatz auftreten und so wird das Netz Schwierigkeiten haben, fremde Daten richtig zu erkennen.

$$loss + \lambda \sum_{j=1}^p \beta_j^2 \quad (2.1)$$

Ridge Regression addiert einen zusätzlichen Bestrafungsterm (engl.: *penalty term*) zur Verlustfunktion (engl.: *loss function*), wobei *loss* die Verlustfunktion, der letzte Term der Bestrafungsterm und $\lambda > 0$ sei. Hier ist darauf zu achten,

²Es sei erwähnt, dass es neben L2 Regularization noch *L1 Regularization* (oder auch *Lasso Regression*) existiert. Diese Methode wird eingesetzt, um Underfitting zu verhindern.

dass λ sinnvoll gewählt wird. Wenn es zu groß gewählt wird, wird zu viel Gewicht hinzugefügt und das Modell tendiert zum *Underfitting*³. [3][18]

2.4 Zusätzliche Methoden

Wenn ein KNN initial trainiert wird, werden die einzelnen Gewichte zufällig gewählt und dann dem Idealwert angenähert. Dieser Prozess kann zeitlich verkürzt werden indem vortrainierte Gewichte eingesetzt werden. Je länger ein Modell trainiert werden muss, desto größer ist die Gefahr des *Overfittings*. Darum wird die Mask R-CNN-Implementierung mit Gewichten initialisiert, die auf dem COCO-Datensatz trainiert wurden.

In einem großen Datensatz beeinflussen einzelne Anomalien das Training nicht. Anders können diese Anomalien einen starken Einfluss in einem kleinen Datensatz haben. Eine hohe Anzahl von trainierbaren Parametern (Gewichten) reagieren darauf empfindlicher und es gilt das Modell durch Parameterminimierung resilienter zu machen. Um die Anzahl an Gewichten, die trainiert werden, zu minimieren, kann das *Backbone*⁴ vereinfacht werden. Hier werden *ResNet50* und *ResNet101*, welche jeweils 50 und 101 Schichten besitzen, miteinander verglichen. Hierbei sollte ResNet50 vorteilhafter sein, da es von beiden vorgestellten Architekturen die simple hat.

Bei einem kleinen Datensatz hilft es die Experimente simpel zu gestalten. Das betrifft auch die Anzahl der Klassen. In dem betroffenen Region wurden zwei verschiedene Krankheiten festgestellt, die als einzelne Klassen deklariert werden können. Um die Datengröße pro Klasse zu erhöhen, werden diese beiden Klassen zu einer Klasse *infection* zusammengefasst.

³Underfitting bezeichnet eine schlechte Performanz des neuronalen Netzes auf sämtliche Daten inkl. dem Trainingsdatensatz.

⁴He et al. bezeichnen die Architektur, die für die Merkmalsextraktion verantwortlich ist, als Backbone. Das Segment, das Klassifizierung, Bounding-Box-Generierung und Maskenerkennung durchführt, wird als *network head* (oder nur *head*) definiert. [13]

Kapitel 3

Konzept und Implementierung

3.1 Konzept

Das Programmablauf wird in einzelne Schritte unterteilt, auf die in den nächsten Kapiteln näher eingegangen werden.

Zuerst müssen die Daten für das Training bzw. für die Erkennung manuell an-




Abbildung 3.1: Gesamtablauf der Anwendung

notiert werden. Diese Metadaten werden dann genutzt, um automatisch Sentinelprodukte¹ mittels einer API, die von der Copernicus zur Verfügung gestellt wird, herunterzuladen. Aus den Produkten werden die relevanten Bänder extrahiert und unter anderem die jeweiligen NDVI-Werte berechnet. Nachdem

¹Aufnahmenpakete der Sentinel-Plattformen werden als Produkte bezeichnet.

die Produkte für das Training vorbereitet wurden, werden die Daten in ein Trainings- und in ein Validierungsdatensatz aufgeteilt. Der folgende Trainingsprozess basiert auf diesen Datensätzen. Sobald das Training abgeschlossen ist, kann die Performanz des Modells getestet werden.

3.2 Annotation

Zu Beginn werden die Regionen, die entweder für das Training benutzt oder überprüft werden, manuell erfasst. Vorrausgesetzte Informationen sind

- Geografische Koordinaten,
- Zeitraum des Befalls und
- Bezeichnung der Infektion.

Als Format dieser Informationen dient *GeoJSON*². GeoJSON enthält nicht nur geografische Daten, sondern ist auch um benutzerdefinierte Eigenschaften (properties) erweiterbar. Die Annotationen sind also GeoJSON-Features, die ein geografisches Polygon mit Metadaten enthalten.

```
1 {
2   "type": "Feature",
3   "properties": {
4     "disease": 1,
5     "from": "2018-07-12T13:00:00Z-7DAYS",
6     "to": "2018-07-12T13:00:00Z+7DAYS"
7   },
8   "geometry": {
9     "type": "Polygon",
10    "coordinates": [[[11.171988617177981,44.574291380353003],
11                     [11.1726616444942,44.574017992242283],
12                     [11.17338129910439,44.575068359984279],
13                     [11.17273129334275,44.575299863118993],
14                     [11.171988617177981,44.574291380353003]]]
15  }
16 }
```

²GeoJSON ist eine Erweiterung des JSON-Format und beschreibt geografische Daten und Geometrien. GeoJSON wird durch den RFC7946-Standard definiert.

Listing 3.1: Annotation

`properties.disease` enthält die eindeutige, numerische Repräsentation der Klasse bzw. Krankheit, die in dieser Region enthalten ist. Die Zuordnung der numerischen Werte und des textuellen Bezeichners werden in einer separaten JSON als Schlüssel-Wert-Paare konfiguriert, wobei der Schlüssel numerisch und der Wert textuell ist. Hier ist, darauf zu achten, dass der Schlüssel ≥ 1 ist, da 0 der implizite Schlüssel der Mask R-CNN-Implementierung für den Hintergrund ist. Diese Eigenschaft ist nur für das Training von Relevanz.

`properties.from` und `properties.to` sind jeweils Start- und Endzeitpunkt, in dem nach verfügbaren Sentinelprodukten gesucht werden soll. Das Format der jeweiligen Eigenschaften kann eine der folgenden Formen haben³:

- `yyyyMMdd`
- `yyyy-MM-ddThh:mm:ss.SSSZ` (ISO-8601)
- `yyyy-MM-ddThh:mm:ssZ`
- `NOW`
- `NOW-<n>DAY(S)` (oder `HOUR(S)`, `MONTH(S)`, usw.)
- `NOW+<n>DAY(S)`
- `yyyy-MM-ddThh:mm:ssZ-<n>DAY(S)`
- `NOW/DAY` (oder `HOUR`, `MONTH` usw.) - Der Wert wird entsprechend (z.B. auf den Tag) gerundet.

Es ist angebracht einen Zeitraum von mehreren Tagen bzw. Wochen zu wählen, da die Sentinel-2-Satelliten keine täglichen Daten liefern und weil eine Infektion typischerweise über einen längeren Zeitraum vorherrscht. Die Zeitspanne ist von der Krankheit abhängig. Hier wurden eine Woche vor und nach dem Aufnahmezeitpunkt genutzt, um nach Produkten zu suchen.

³Die Formate basieren auf der `sentinelsat`-Version 0.12.2.

3.3 Suche nach Sentinelprodukte

Der *Copernicus Open Access Hub*⁴ ermöglicht freien und offenen Zugriff auf Sentinel-Produkte. Die Daten sind sowohl über eine grafische Oberfläche als auch über eine REST-API verfügbar. Voraussetzung für beide Optionen ist ein Account, der über die grafische Oberfläche erstellt werden kann.

Die Nutzung der Schnittstelle erfolgt über die Python-Bibliothek *sentinelsat*⁵. Bei einer Anfrage müssen die GeoJSON-Dateien in WKT⁶ umgewandelt werden, was von der Bibliothek übernommen werden kann. Die WKT-Geometrie wird als *footprint* (dt.: Fußabdruck) bezeichnet. Solang es nicht anders angegeben wird, gibt die Copernicus-API Produkte zurück, die die RoI schneiden. Desweiteren wird der Plattformname statisch als 'Sentinel-2' definiert, damit keine Produkte von den anderen Sentinelplattformen zurückgegeben werden. Der Suchzeitraum wird aus der jeweiligen GeoJSON-Datei übernommen. Sollten für die Suchanfragen keine Produkte existieren, wird die Anwendung beendet, da es keine Basis gibt, auf der das Netzwerk trainiert werden kann. Eventuell muss bei so einem Fall der Zeitraum erweitert und Prozess wiederholt werden. Bei vorhandenen Produkten lädt das Skript diese herunter. Die Produkte werden in einem komprimierten Format geliefert und enthalten neben zusätzlichen Informationen, Banddaten in separaten Dateien im JPEG2000-Format⁷.

Für jedes Produkt, das zur aktuellen Annotation gehört, wird ein neuer Eintrag zu einer *FeatureCollection* hinzugefügt. Für die spätere Entwicklung sind die Annotationen so leichter zu finden und bearbeitbar. Außerdem bleiben dadurch die Originaldaten unberührt. Dieser Schritt wird für jede vorhandene Annotationsdatei wiederholt. Anschließend werden die Bilddateien für B4 und B8 aus dem Produkt extrahiert.

⁴<https://scihub.copernicus.eu/>

⁵<https://sentinelsat.readthedocs.io/en/stable>

⁶WKT (Well-known text) ist eine Markup-Sprache zur Repräsentation von geometrischen Objekten auf Karten und räumlichen Referenzsystemen.

⁷JPEG 2000 genau wie GeoTIFF ist ein Bildformat in dem auch Metadaten abgelegt werden können. So sind Pixel geografischen Koordinaten zuordbar.




Abbildung 3.2: Ablaufdiagramm der Beschaffung der Sentinelprodukte

3.4 Aufbereitung der Sentineldaten

Originale Sentinel-2-Aufnahmen haben eine Größe von $10980 * 10980$ px und müssen deshalb deutlich verkleinert werden, um Speicherressourcen zu minimieren. Vor allem da nur kleine Ausschnitte von wenigen Pixeln benötigt werden.

Zu Beginn werden alle Elemente aus der vorher erstellten *FeatureCollection* geladen und nacheinander bearbeitet. Jedes Produkt hat ein eigenes Koordinatenreferenzsystem (CRS, Coordinate Reference System) und unter Umständen

unterscheiden sich die Systeme des Produktes und des Polygons⁸. Diese müssen gleich sein, um miteinander agieren zu können. Das Produkt-CRS kann aus den extrahierten Bändern gelesen und dann dazu genutzt werden, um die Annotationskoordinaten in eben dieses zu projizieren.

Nachdem abgesichert wurde, dass die RoI in dem Sentinelprodukt enthalten ist, wird aus den Bändern die RoI samt einem vorher definierten Rand ausgeschnitten. Der Rand ist später bei der Data Augmentation hilfreich. Gleichzeitig erstellt die Anwendung eine gleich große binäre Maske, wobei die Elemente der Maske mit den Pixeln der RoI korrespondieren. Die Elemente, die die RoI repräsentieren, enthalten einen wahren Wert.

Nun wird der NDVI aus den B4- und B8-Ausschnitten, wie in Kapitel 1.2 ge-



Abbildung 3.3: V.l.n.r. B4 (RED), B8 (NIR), NDVI

zeigt, berechnet (s. Abb. 3.3). Das Ergebnis wird nun mittels Data Augmentation vervielfältigt. Dazu wird es vier mal um 90°gedreht. Danach wird jedes rotierte Bild horizontal und vertikal gespiegelt. Darauf werden zehn mal aus den rotierten und gespiegelten Daten zufällig Bilder in der Größe von 16*16 px ausgeschnitten. Durch diese Operationen vergrößert sich die Grundgesamtheit um den Faktor 80. Jede Operation wird ebenfalls auf die entsprechende Maske angewandt. Dabei wird darauf geachtet, dass die Maske nicht vollständig aus falschen Werten besteht und dass die manipulierten Dateien ebenfalls der *FeatureCollection* hinzugefügt werden.

3.5 Trainings- und Validierungsdatensatz

Die berechneten NDVI-Bilddateien und deren Masken bilden die Gesamtheit des Datensatzes. Um das Modell trainieren und testen zu können, muss diese

⁸Nach RFC 7946 ist das geografische Referenzsystem *World Geodetic System 1984* (WGS 84) das Standardsystem.[5]

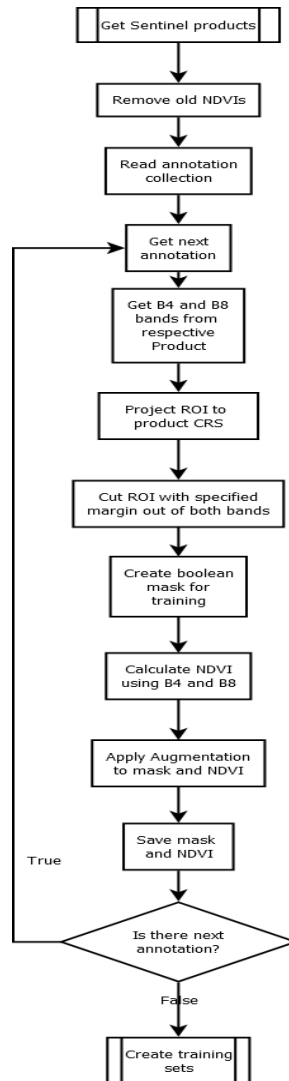


Abbildung 3.4: Ablaufdiagramm der Aufbereitung

Gesamtheit aufgeteilt werden.

- Trainingsdatensatz

Hiermit werden die Gewichte des neuronalen Netzwerkes trainiert.

- Validierungsdatensatz

Dieser Datensatz wird genutzt, um das trainierende Modell wiederholt zu evaluieren. Die Parameter in dem Modell werden auf Basis dieser Evaluation verändert, um das Idealergebnis zu approximieren.

- Testdatensatz

Während der Validierungsdatensatz während des Trainings genutzt wird, ist der Testdatensatz zu Evaluation des fertig trainierten Modells geeignet. Das KNN sieht also die Elemente nicht während des Trainingpro-

zesses und repräsentiert „fremde“ Daten. Damit ist der Testdatensatz ein besserer Indikator der Leistung des Modells als der Validierungsdatensatz.



Abbildung 3.5: Darstellung der relativen Datensatzverteilung[20]

In welchem Verhältnis die Datensätze aufgeteilt werden, hat einen Einfluss auf das Training und hängt von der eigentlichen Größe des gesamten Datensatz und von dem trainierten Modell ab. Komplexere Modelle benötigen einen größeren Validierungsdatensatz, während ein Modell mit weniger Parametern mit einem kleineren auskommt.[20] Typischerweise besteht jedoch der Trainingsdatensatz aus dem größten Teil.

Hier wird zunächst die Gesamtmenge zwischen einem unbestimmten Teildatensatz (80% der Gesamtheit) und dem Testdatensatz (20% der Gesamtheit) aufgeteilt. Danach teilt sich der Teildatensatz in den Trainingsdatensatz (80% des Teiles) und in den Validierungsdatensatz (20% des Teiles). Die hier angewandte prozentualen Werte sind häufig angewandte initiale Verhältnisse und können bei Bedarf angepasst werden. Die geteilten Mengen werden unterschiedlichen Orten abgelegt und für jede Sammlung wird jeweils eine neue *FeatureCollection* erzeugt, die die Annotationen der entsprechenden Elemente enthalten.

3.6 Training

Mit den vorbereiteten und aufgeteilten Daten kann nun das Netzwerk angelehrt werden. In dieser Arbeit wurde eine Implementierung⁹ des kalifornischen Unternehmens Matterport, Inc. erweitert und genutzt. Matterport stellte den Quellcode 2017 unter MIT-Lizenz der Öffentlichkeit zur freien Verfügung. Das neuronale Netz wurde mittels Python 3, Tensorflow und Keras im-

⁹https://github.com/matterport/Mask_RCNN




Abbildung 3.6: Ablaufdiagramm der Datensatzaufteilung

plementiert. Zum Training eigener Daten müssen die zwei Python-Basisklassen Dataset und Config erweitert werden.

Dataset

Die Klasse Dataset bietet einen Weg, eigene Datensätze in das Modell zu laden, da die Daten in unterschiedlichen Formaten vorkommen können. Für die Erweiterung erbt die neue Klasse CropDiseaseDataset von Dataset und überschreibt die Methoden `Dataset.load_mask`, `Dataset.load_image` und `Dataset.image_reference`. Zusätzlich wurde die Methode `CropDiseaseDataset.load_crop_disease` implementiert. Eine Instanz von Dataset bzw. CropDiseaseDataset bildet nicht die gesamte Datenmenge ab, sondern jeweils einen spezifizierten Subdatensatz, die in Kapitel 3.5 definiert wurden. So muss jeder Teil separat instanziiert werden.

`CropDiseaseDataset.load_crop_disease` fügt dem Objekt die Klassen- bzw.

Bildinformationen wie eindeutige Bezeichnung und Dateipfad durch die internen Methoden `Dataset.add_class` bzw. `Dataset.add_image` hinzu.

`CropDiseaseDataset.load_image` lädt die eigentliche Bilddatei in den Arbeitsspeicher. Die NDVI-Werte wurden als Grauskalenbilder gespeichert und müssen in ein RGB-Format konvertiert werden. Es ist möglich durch Anpassungen des Mask RCNN-Codes, auch Dateien mit mehr oder weniger als drei Farbkanälen zu nutzen. Jedoch verursachte das Fehler, die zum Zeitpunkt der Verschriftlichung nicht gelöst wurde. Da es sich dabei um keinen kritischen Fehler handelt, wurde dieser durch die Konvertierung umgangen. Da die NDVI-Werte zwischen -1 und 1 liegen und Farbwerte aus ganzzahligen Werten bestehen, werden die NDVI-Werte mit 255 multipliziert, bevor sie schließlich hinzugefügt werden.

`CropDiseaseDataset.load_mask` liest die binären Masken aus den Dateien und ordnet sie einer Klasse und einem Bild zu.

Die Methode `CropDiseaseDataset.image_reference` gibt den vollständigen Dateipfad einer Bilddatei zurück.

Config

Die Klasse `Config` ist eine Sammlung von Parametern, die zur Konfiguration des Modells genutzt werden. Diese Parameter können entsprechend angepasst werden und haben jeweils Einfluss auf das Training bzw. auf die Erkennung. Es wird hier nur auf die Parameter eingegangen, die explizit im Rahmen der Entwicklung verändert wurden, um das Ergebnis des Trainings zu verbessern. Die Parameterbezeichnung ist der Name des Parameters, so wie er in `Config` deklariert wurde. Die Erklärung beschreibt den Parameter näher. Die angegebenen Werte sind alle möglichen Werte, die in der Entwicklung genutzt wurden. Welche Werte bei welchem Trainingsdurchlauf genutzt wurden, wird im Kapitel ?? beschrieben.

Parameterbezeichnung: BACKBONE

Erklärung: Die Backbone-Architektur mit der das Modell gebildet wird.

Werte: resnet50

Parameterbezeichnung: DETECTION_MIN_CONFIDENCE

Erklärung: Minimalste Wahrscheinlichkeit einer Detektion, um sich als vorhergesagte Instanz zu qualifizieren. Detektionen mit einer Wahrscheinlichkeit niedriger als dieser Wert werden ignoriert.

Werte: 0

Parameterbezeichnung: IMAGE_MAX_DIM

Erklärung: Wichtig für IMAGE_RESIZE_MODE. Bildhöhe und -breite werden auf diesen Wert vergrößert.

Werte: 128 (in px)

Parameterbezeichnung: IMAGE_RESIZE_MODE

Erklärung: Methode mit der ein Bild vergrößert bzw. verkleinert wird. Die gewählte Option vergrößert die Datensätze auf IMAGE_MAX_DIM*IMAGE_MAX_DIM und füllt das Bild mit 0-Werten, sollte das Ausgangsbild kein Quadrat sein.

Werte: square

Parameterbezeichnung: IMAGES_PER_GPU

Erklärung: Bilder die pro Schritt gleichzeitig für das Training in den Speicher geladen werden. Dieser Wert ist - je nachdem man auf der CPU oder auf der GPU trainiert - abhängig von der Größe der Arbeitsspeichers oder Grafikspeichers. Für die Detektion ist nur ein Bild pro Schritt erlaubt.

Werte: 1, 4

Parameterbezeichnung: LEARNING_RATE

Erklärung: Die Lernrate gibt an, wie stark die Gewichte des Netzwerkes korrigiert werden. Wenn dieser Wert zu klein ist, kann die Konvergenz zum Ideal sehr lange dauern. Ein zu hoher Wert kann das Ideal überschießen oder sogar dafür sorgen, dass die Lernkurve divergiert. He et al. nutzen in ihrer Ausarbeitung einen Wert von 0.02.[13] Dieser sorgt jedoch laut den Entwicklern von Matterport zu einem explosionartigen Anstieg der Gewichte, weswegen sie sich für 0.001 entschieden haben.[1] Hier werden beide Werte untersucht.

Werte: 0.001, 0.2

Parameterbezeichnung: NUM_CLASSES

Erklärung: Die Anzahl der Klassen, die trainiert werden. Hier ist darauf zu achten, dass der Hintergrund als eigene Klasse gesehen wird, auch wenn diese nicht explizit definiert wird. Daher muss die zusätzliche Klasse mit in diesen

Wert einberechnet werden.

Werte: 2

Parameterbezeichnung: RPN_ANCHOR_SCALES

Erklärung:

Werte:

Parameterbezeichnung: STEPS_PER_EPOCH

Erklärung: Anzahl der Trainingsschritte bis eine Epoche abgeschlossen ist. Der Wert ist typischer abhängig von der Größe des Trainingsdatensatzes und wie viele Bilder pro Schritt prozessiert werden.

Werte: $\frac{SIZE_{Train}}{IMAGES_PER_GPU}$

Parameterbezeichnung: USE_MINI_MASK

Erklärung: Wenn dieser bool'sche Wert wahr ist, werden Instanzmasken zu einer spezifizierten Größe verkleinert. Hier wird das jedoch deaktiviert, da die Eingangsbilder klein genug sind und diese Operation nicht nötig ist.

Werte: False

Parameterbezeichnung: WEIGHT_DECAY

Erklärung: Einflussgröße der L2 Regulization.

Werte: 0.01, 0.005, 0.001

Abbildungsverzeichnis

1.1	Region of Interest	2
1.2	Künstliches neuronales Netz	6
1.3	CNN	7
1.4	Instansegmentierung	8
1.5	Mask R-CNN-Architektur	8
1.6	FCN-Architektur	9
1.7	Mask R-CNN vs. FCIS	10
2.1	Beispiel Overfitting	13
3.1	Gesamtablauf der Anwendung	16
3.2	Ablaufdiagramm der Beschaffung der Sentinelprodukte	20
3.3	B4 - B8 - NDVI	21
3.4	Ablaufdiagramm der Aufbereitung	22
3.5	Datensatzverteilung	23
3.6	Ablaufdiagramm der Datensatzaufteilung	24

Tabellenverzeichnis

1.1 Räumliche und spektrale Auflösungen von Sentinel-2A[10]	4
1.2 Mask R-CNN im Vergleich	10

Literaturverzeichnis

- [1] W. Abdulla. Mask r-cnn for object detection and instance segmentation on keras and tensorflow. https://github.com/matterport/Mask_RCNN, 2017. [Zuletzt besucht: 06.01.2019].
- [2] W. Abdulla. Splash of color: Instance segmentation with mask r-cnn and tensorflow. <https://engineering.matterport.com/splash-of-color-instance-segmentation-with-mask-r-cnn-and-tensorflow-7c761>, 2018. [Zuletzt besucht: 22.12.2018].
- [3] Anuja Nagpal. L1 and l2 regularization methods. <https://towardsdatascience.com/l1-and-l2-regularization-methods-ce25e7fc831c>, 2017. [Zuletzt besucht: 09.01.2019].
- [4] Bharath Raj. Data augmentation | how to use deep learning when you have limited data - part 2. <https://medium.com/nanonets/how-to-use-deep-learning-when-you-have-limited-data-part-2-data-augmentation-7c761>, 2018. [Zuletzt besucht: 09.01.2019].
- [5] H. Butler, M. Daly, A. Doyle, S. Gillies, S. Hagen, and T. Schaub. The GeoJSON Format. RFC 7946, IETF, August 2016.
- [6] C. Consortium. Coco 2018 object detection task. <http://cocodataset.org/#detection-2018>, 2018. [Zuletzt besucht: 06.01.2019].
- [7] Copernicus. Copernicus in brief. <https://www.copernicus.eu/en/about-copernicus/copernicus-brief>. [Zuletzt besucht: 15.12.2018].
- [8] N. Corporation. Convolutional neural network (cnn). <https://developer.nvidia.com/discover/convolutional-neural-network>, 2019. [Zuletzt besucht: 04.01.2019].

- [9] ESA. Level-2a algorithm overview. <https://sentinel.esa.int/web/sentinel/technical-guides/sentinel-2-msi/level-2a/algorithm>, 2018. [Zuletzt besucht: 20.12.2018].
- [10] ESA. Radiometric resolutions. <https://earth.esa.int/web/sentinel/user-guides/sentinel-2-msi/resolutions/radiometric>, 2018. [Zuletzt besucht: 20.12.2018].
- [11] ESA. Resolutions. <https://earth.esa.int/web/sentinel/user-guides/sentinel-2-msi/resolutions>, 2018. [Zuletzt besucht: 20.12.2018].
- [12] A. A. Gitelson, Y. Gritz, and M. N. Merzlyak. Relationships between leaf chlorophyll content and spectral reflectance and algorithms for non-destructive chlorophyll assessment in higher plant leaves. *Journal of Plant Physiology*, 160(3):271 – 282, 2003.
- [13] K. He, G. Gkioxari, P. Dollár, and R. B. Girshick. Mask R-CNN. *CoRR*, abs/1703.06870, 2017.
- [14] G. A. F. Hendry, J. D. HOUGHTON, and S. B. BROWN. The degradation of chlorophyll — a biological enigma. *New Phytologist*, 107(2):255–302, 1987.
- [15] J. Hui. Image segmentation with mask r-cnn. https://medium.com/@jonathan_hui/image-segmentation-with-mask-r-cnn-ebe6d793272, 2018. [Zuletzt besucht: 06.01.2019].
- [16] C. Mattupalli, C. A. Moffet, K. N. Shah, and C. A. Young. Supervised classification of rgb aerial imagery to evaluate the impact of a root rot disease. *Remote Sensing*, 10(6), 2018.
- [17] NASA. Measuring vegetation (ndvi & evi). https://earthobservatory.nasa.gov/features/MeasuringVegetation/measuring_vegetation_2.php, 2000. [Zuletzt besucht: 13.12.2018].
- [18] Prashant Gupta. Regularization in machine learning. <https://towardsdatascience.com/regularization-in-machine-learning-76441ddcf99a>, 2017. [Zuletzt besucht: 09.01.2019].

- [19] S. Ren, K. He, R. B. Girshick, and J. Sun. Faster R-CNN: towards real-time object detection with region proposal networks. *CoRR*, abs/1506.01497, 2015.
- [20] T. Shah. About train, validation and test sets in machine learning. <https://towardsdatascience.com/train-validation-and-test-sets-72cb40cba9e7>, 2017. [Zuletzt besucht: 16.01.2019].
- [21] U.S. Department of the Interior. What are the band designations for the landsat satellites? <https://sentinel.esa.int/web/sentinel/technical-guides/sentinel-2-msi/level-2a/algorithm>, n.d. [Zuletzt besucht: 24.12.2018].
- [22] J. Verrelst, J. Muñoz, L. Alonso, J. Delegido, J. P. Rivera, G. Camps-Valls, and J. Moreno. Machine learning regression algorithms for biophysical parameter retrieval: Opportunities for sentinel-2 and -3. *Remote Sensing of Environment*, 118:127 – 139, 2012.

Erklärung

Ich versichere, dass ich die vorliegende Arbeit selbstständig und nur unter Verwendung der angegebenen Quellen und Hilfsmittel angefertigt habe, insbesondere sind wörtliche oder sinngemäße Zitate als solche gekennzeichnet. Mir ist bekannt, dass Zuwiderhandlung auch nachträglich zur Aberkennung des Abschlusses führen kann.

Ich versichere, dass das elektronische Exemplar mit den gedruckten Exemplaren übereinstimmt.

Ort:

Datum:

Unterschrift: